

Análisis de datos

Carrera de Especialización en
Inteligencia Artificial
B4 2025



Programa de la materia

1 **Introducción al análisis de datos**
Flujo de trabajo típico. Aplicaciones. Configuración del entorno. Introducción a las principales bibliotecas.
28/8

2 **Análisis exploratorio de datos (EDA)**
Tipos de variables. EDA y visualización de variables numéricas y categóricas. Identificación de valores faltantes y outliers. Relación entre variables.
4/9

3 **Taller práctico - parte 1**
Trabajo en grupos: EDA y visualización inicial de un dataset. Buenas prácticas. Puesta en común.
11/9

4 **Preprocesamiento y limpieza de datos**
Presentación de grupos de trabajo final. Prevención de data leakage. Tratamiento de datos faltantes. Tratamiento de outliers.
18/9

5 **Feature engineering**
Cardinalidad, codificación, discretización. Desbalance. Creación de nuevos features. Normalización y estandarización.
25/9

6 **Reducción de dimensionalidad**
Métodos de extracción y técnicas para selección de features. **Bonus:** EDA de datos no estructurados.
2/10

7 **Taller práctico - parte 2**
Trabajo en grupo: preprocesamiento y feature engineering de un dataset. Buenas prácticas. Puesta en común. Consultas.
9/10



13/10 - límite para compartir el material para la exposición final.

8 **Exposición final**
Exposición de trabajos finales. **Bonus:** Herramientas para automatizar el EDA y otras tareas del flujo de trabajo.
16/10

¿Qué es el análisis exploratorio de datos (EDA)?




- El análisis exploratorio sirve para resumir, visualizar y entender los datos.
- Útil para tomar decisiones sobre el manejo de outliers y datos faltantes.
- Ayuda a identificar transformaciones necesarias antes de entrenar modelos de ML: escalamiento, normalización, balance, codificación, discretización, etc.
- Facilita la identificación de patrones, relaciones y la evaluación de la relevancia de los datos.

Variables aleatorias y datasets

- Una variable aleatoria (v.a.) es una forma de mapear los resultados de algún fenómeno aleatorio a números.
- Constituyen una herramienta fundamental para modelar y analizar fenómenos que involucran incertidumbre o aleatoriedad.
- Las columnas de un dataset pueden considerarse como un conjunto de observaciones de una variable aleatoria, tomada de una población más grande.

Entonces, todo lo visto en Probabilidad se puede aplicar a las columnas de un dataset



Ejemplos de v. aleatorias en el dataset del Titanic

Columna	Fenómeno aleatorio
Survived (¿sobrevivió?)	Varía aleatoriamente según factores como la ubicación en el barco, el acceso a botes salvavidas, la clase social y decisiones personales durante el naufragio.
Sex	Varía aleatoriamente según la composición de quienes decidieron o pudieron viajar. Influenciada por factores sociales como roles de género o motivos del viaje.
Age	Variable en función de la población que decidió o pudo viajar en el Titanic. Condicionada por el año de nacimiento de las personas y las circunstancias que los llevaron a ese viaje.
SibSp (cantidad de hermanos o esposo/a)	Influenciada por decisiones familiares (ej., viajar juntos), tamaño de la familia y factores sociales de la época.
Fare (tarifa)	Variable según factores como la clase (primera, segunda, tercera), el puerto de embarque o decisiones individuales de compra.
Embarked (puerto de embarque)	Influenciada por el lugar de origen, itinerario personal y disponibilidad de pasajes desde cada puerto.

Tipos de variables

Cosas que puedo contar o medir

Cuantitativas (numéricas)

Se puede aplicar operaciones matemáticas

Discretas

Toman valores enteros

Ejemplos:

Cantidad de hijos

Número de visitas al médico

Número de ventas

Cantidad de autos de una familia

Continuas

Pueden tomar cualquier valor dentro de un rango

Temperatura

Altura

Edad

Salario

Velocidad

Cualidades o información que no se puede medir

Categorías (cualitativas o atributos)

Nominales

Sin orden

Estado civil

Nombre de ciudad

Día de la semana

Nacionalidad

Ordinales

Tienen un orden específico (jerarquía o magnitud)

Talles de ropa (S, M, L)

Opiniones (muy de acuerdo, de acuerdo,...)

Nivel de educación (secundario, terciario, universitario)

Seniority

Día, mes es nominal porque febrero no tiene mas importancia que enero


Algunas consideraciones interesantes

- Una variable categórica se puede representar con números (que actúan como un encoding).
- La **edad** en general se considera una variable continua pero generalmente se mide y reporta como discreta (Ej., en años). → Naturaleza de los datos vs. cómo se refleja.
- Las variables **binarias** (Sí/No, 1/0, True/False) son un caso particular de las categóricas nominales.
- Las **fechas** tienen una doble naturaleza:
 - Numérica, cuando interesa medir tiempo transcurrido o tendencias.
 - Categórica, cuando interesa agrupar eventos en una fecha específica (Ej., analizar las ventas en un día particular de la semana).
Normalmente la fecha es categorica
- ¿Qué pasa con las **coordenadas geográficas**?
Puede ser numerica o categorica nominal, depende de como se trate.
Por ejemplo, se puede usar para calcular distancias (numerica; se hizo una operacion).
Si la coordenada solo se utiliza para representar una ubicacion, es categorica



Ejercicio opcional

Resolver el ejercicio de la Notebook `clase_02_ejercicio.ipynb` (se encuentra en la carpeta "recursos" del repositorio).



Estadística descriptiva



- Las métricas descriptivas permiten estimar las características de una variable aleatoria utilizando una muestra de datos.
- La distribución de datos numéricos se puede caracterizar en términos de su tendencia central, su variabilidad (dispersión) y su forma.
- Los datos categóricos se pueden describir a partir de cantidades, proporciones y porcentajes de los distintos valores o categorías.

Momentos

Los momentos son medidas que capturan diferentes aspectos de una distribución de datos.

Momento de orden k
(calculado respecto al origen)

$$\mu'_k = \frac{1}{n} \sum_{i=1}^n x_i^k$$


Si k=1 --> u es la media

Momento central de orden k
(calculado respecto a la media)

$$\mu_k = \frac{1}{n} \sum_{i=1}^n \left(x_i - \bar{x} \right)^k$$



1. Exploración de datos numéricos



Tendencia central

- 1 MEDIA** La media da una idea del valor central de los datos, alrededor del cual se mueven los datos
- 2 MEDIANA** La mediana no se ve afectada por valores extremos, a diferencia de la media
- 3 MODA** La moda son los valores que mas se repiten, puede haber varios por lo que se dice multimodal

Dispersión

- 4 VARIANZA** Muestra que tan dispersos estan los datos respecto la media
- 5 DESVIACIÓN ESTÁNDAR** El desvio recupera la unidad de los datos trabajados. Muestra, en promedio, la dispersion respecto de la media
- 6 CUARTILES Y RANGO INTERCUARTIL**
Los cuartiles dividen los datos en 4 partes iguales: Q1, Q2, Q3
Ejemplo, Q1: el 25% es $\leq$ al valor

Forma




- 7 SKEWNESS** (asimetria)
Entre el Q1 y Q3 se tiene el 50% de los datos
- 8 CURTOSIS**
El IC muestra que tan dispersos estan los datos alrededor de la mediana

Actividad **VARIABLES NUMERICAS**



Tendencia central: media, mediana y moda

Son distintas formas de medir el
"centro" en un conjunto numérico de
datos.



Media, mediana y moda: ejemplo

Ejemplo (notas de alumnos): {9, 9, 8, 9, 10, 5}

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\text{Media} = \frac{9+9+8+9+10+5}{6} = 8,33$$

Representa la nota si todos se hubieran sacado lo mismo

Mediana = valor del medio de una lista ordenada

$$\text{Mediana} = \{5, 8, \underbrace{9, 9}, 9, 10\}$$

(Media de los dos valores del centro por ser cantidad par)

La nota del medio. Una mitad de la clase sacó menos de 9 y la otra mitad, más que 9.

Moda = el valor más frecuente

$$\text{Moda} = \{\underbrace{9, 9}, 8, \underbrace{9}, 10, 5\}$$


Puede o no haber moda. Puede haber más de una (bimodal, trimodal, multimodal).

La nota más frecuente fue 9.

Medidas de dispersión: varianza y desviación estándar

- Sirven para medir qué tan “desparramados” están los datos alrededor de la media.
- La desviación estándar suele ser más fácil de interpretar.

$$\sigma^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2$$
$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2}$$



Varianza y desviación estándar - ej.

$$C1 = \{-10, 0, 10, 20, 30\}$$

$$C2 = \{8, 9, 10, 11, 12\}$$



$$\bar{\mu}_1 = \frac{-10+0+10+20+30}{5} = 10$$

$$\bar{\mu}_2 = \frac{8+9+10+11+12}{5} = 10$$

$$\sigma_1^2 = \frac{(-10-10)^2 + (0-10)^2 + (10-10)^2 + (20-10)^2 + (30-10)^2}{4}$$

$$\sigma_2^2 = \frac{(8-10)^2 + (9-10)^2 + (10-10)^2 + (11-10)^2 + (12-10)^2}{4}$$

$$\sigma_1^2 = 250$$

$$\sigma_2^2 = 2,5$$

$$\sigma_1 = \sqrt{\sigma_1^2} = \sqrt{250} = 15,8$$

$$\sigma_2 = \sqrt{\sigma_2^2} = \sqrt{2,5} = 1,58$$

Cuantiles

- Son valores que dividen un conjunto de datos **ordenados** en partes iguales.
- Se usan para analizar la distribución de los datos.
- Tipos de cuantiles más comunes:
 - **Cuartiles**: dividen los datos en 4 partes iguales. ←
 - **Deciles**: dividen los datos en 10 partes iguales.
 - **Percentiles**: dividen los datos en 100 partes.

Usado generalmente para EDA




Cuartiles

- Q1 o primer cuartil o cuartil inferior: el 25% de los datos son menores o iguales a él.
- Q2 o segundo cuartil: es el valor que divide al conjunto en dos mitades iguales.
- Q3 o tercer cuartil o cuartil superior: El 75% de los datos son menores o iguales a él.


En términos de la función de distribución acumulada (CDF):

- Q1 es el valor x tal que $F(x) = P(X \leq x) = 0,25$
- Q2 es el valor tal que $F(x) = P(X \leq x) = 0,50$
- Q3 es el valor tal que $F(x) = P(X \leq x) = 0,75$



Cuartiles y rango intercuartil - Ejemplo

Datos: {4, 4, 10, 11, 15, 7, 14, 12, 6}




Rango total = 15 - 4 = 11 --> 10% = 1.1 - 20% = 2.2

IQR >> 10-20% por lo tanto la parte central de los datos esta bastante dispersa

Rango intercuartil (IQR)

El IQR mide la dispersión del 50% central de los datos.



- IQR pequeño $\rightarrow$ centro de datos concentrado.
- IQR grande $\rightarrow$ centro de datos disperso.


El IQR se considera pequeño si es menor al 10%-20% del rango total (máx - mín).

Visualización de datos numéricos

Distribución (KDE) del largo de la aleta de los pingüinos para cada especie



Función de densidad (mirando la parte de arriba)

VIOLIN PLOT



BOXPLOTS

Boxplots del largo de la aleta. Izquierda: todos los datos juntos. Derecha: para cada especie




Medidas de forma: asimetría y curtosis

- Se usan para describir la forma y comportamiento de una distribución de datos.
- Permiten detectar si se desvían de la "normalidad".
- Ayudan a evaluar patrones no evidentes (sesgos, outliers) que no se detectan con medias o desviaciones estándar.
- Se utilizan para distribuciones continuas.

Se utiliza para comparar con una distribución Normal y ver si se desvía o no.
Si los datos se distribuyen normal, se puede aplicar test estadísticos.

Algunos modelos se comportan mejor cuando la distribución de los datos es normal






Asimetría (Skewness)

- Es una medida de la simetría de la distribución de los datos con respecto al valor central.
- Los datos reales casi siempre presentan asimetría.
- En casos de asimetría, la media deja de ser una buena representación del centro.

$$\text{Asimetría} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^3}{\sigma^3}$$

Momento de orden 3


Normaliza el valor del resultado



Para estos casos la media deja de representar el centro de los datos

Reglas para evaluar la asimetría

- Entre $-0,5$ y $0,5$ se considera aproximadamente simétrica.
- Entre -1 y $-0,5$ ó entre $0,5$ y $+1$ se considera moderadamente asimétrica.
- Menor que -1 ó mayor que $+1$ se considera altamente asimétrica.



Curtosis

- Es una medida del peso de las "colas" de la distribución (cuántos datos hay hacia los extremos).
- Para una distribución Normal estándar, la curtosis es 3.

La curtosis determina cuanto pesan los valores en los extremos (outliers)

$$Curtosis = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^4}{\sigma^4}$$

Momento de orden 4



Curtosis exceso

- La curtosis exceso es igual a la curtosis menos 3. Sirve para comparar la curtosis de los datos con la una distribución normal.
- Una curtosis exceso positiva puede indicar muchos datos en las colas y, por ende, la presencia de outliers.

Evaluación de la curtosis

Convención para la curtosis exceso: = Curtosis - Curtosis de la normal

- Cerca de 0: "mesocúrtica", se considera Normal.
- Mayor que 0: "leptocúrtica" (colas pesadas) --> ¿outliers?
- Menor que 0: "platicúrtica" (colas menos pesadas)
menor presencia de datos extremos que la normal



En este ejemplo:

- Distribución de Laplace con $\mu = \frac{1}{\sqrt{2}}$
- Normal estándar $\mu = 0, \sigma^2 = 1$
- Uniforme entre $\pm\sqrt{3}$

*Fuente

→ 2. Exploración de datos categóricos

Para variables numericas el EDA suele ser bastante estandar, para categoricas no es asi.



Concentración de categorías

- 1 MODA** Categoría con mayor frecuencia
- 2 PROPORCIÓN DE LA MODA** respecto del total de muestras
- 3 MULTIMODALIDAD** Puede haber uno o mas modas

Distribución y frecuencia


- 4 FRECUENCIA ABSOLUTA** Cantidad de veces que aparece cada categoria
- 5 FRECUENCIA RELATIVA** Cantidad de veces que aparece la categoria respecto del total de muestras
- 6 RANGO DE FRECUENCIAS** Permite ver que tan desbalanceada estan las categorias = $\text{max frec abs} - \text{min frec abs}$

Diversidad o variabilidad

- 7 CARDINALIDAD** Cantidad de categorias (datos diferentes)
- 8 ENTROPÍA DE SHANNON**
Métrica que indica que tanta incertidumbre hay con respecto a una variable
El maximo valor de la entropia = $\log(\text{cardinalidad})$


Si la entropia de Shannon es proxima al maximo, entonces hay mucha incertidumbre

Actividad VARIABLES CATEGÓRICAS



Medidas de concentración de categorías

1. **Moda:** valor más frecuente
2. **Proporción de la moda:** qué proporción del total está representado por la moda.
3. **Multimodalidad:** permite detectar si la distribución está dominada por una sola categoría.



categoría	cantidad
cat.1	5
cat.2	10
cat.3	15
cat.4	10
cat.5	5


moda

Medidas de distribución y frecuencia

4. **Frecuencia absoluta.** número de veces que aparece cada categoría.

5. **Frecuencia relativa.** Proporción de cada categoría respecto al total de observaciones.

6. **Rango de frecuencias.** diferencia entre la categoría más frecuente y la menos frecuente.



categoría	cantidad
cat.1	5
cat.2	10
cat.3	15
cat.4	10
cat.5	5

Entropía de Shannon

La incertidumbre de Shannon o entropía de Shannon mide la incertidumbre o diversidad asociada a una fuente de información.

$$H(X) = - \sum_{i=1}^n p_i \log_2 p_i$$



p_i : proporción de la categoría i
(frecuencia relativa de la categoría).
 n : número de categorías (**cardinalidad**)

En variables categóricas, la entropía mide cuán dispersa o uniforme es la distribución de frecuencias.

- **Mayor entropía** → más incertidumbre sobre a qué categoría pertenece una observación elegida al azar. Las categorías están equilibradas o bien distribuidas.
- **Menor entropía** → hay poca incertidumbre. Una o pocas categorías dominan al resto.
- **Entropía máxima** → Para n categorías, la entropía máxima es $\log_2(n)$. Se da cuando todas las categorías son igualmente probables.

Visualización de datos categóricos

Para complementar las métricas, es recomendable usar diferentes visualizaciones



Algunas visualizaciones útiles

- Gráficos de barras: muestran la frecuencia de cada categoría. absoluta
- Gráficos de torta: explican las proporciones (frecuencias) relativas.

Además:


- Tablas de frecuencia.
- Tablas de contingencia (cross-tab): revelan la relación entre dos variables categóricas.

Visualización de datos categóricos

De todas las muestras de
pingüinos, 124 son de la especie
Gentoo y viven en la isla Biscoe

TABLA DE CONTINGENCIA

Número de pingüinos de cada especie en función de la isla donde habitan



Relaciones entre variables





Grafico de dispersion

- Numérica-numérica: Scatterplots, pairplots, matriz de correlación. Ejemplo: altura y peso
- Numérica-categorica: Boxplots, violinplots, etc. Ejemplo: altura y genero
- Categorica-categorica: gráficos de barras y tablas de contingencia. Ejemplo: estado civil y ciudad

Relaciones entre variables

Pairplot: Scatterplots entre pares de variables

Cuando coinciden las variables se dibuja un histograma, en otro caso un scatterplot



Análisis descriptivo

Resumen



EDA variables numéricas



Tendencia central

- 1 Media: valor promedio.
- 2 Mediana: en un conjunto ordenado de números, es el valor que se encuentra en el medio.
- 3 Moda: valor más frecuente.

Dispersión

- 4 Varianza: dispersión de los datos con respecto a la media. Promedia diferencias al cuadrado.
- 5 Desviación estándar: dispersión con respecto a la media pero en las mismas unidades que los datos.
- 6 Cuartiles y rango intercuartil (IQR): otra forma de cuantificar dispersión de los datos.

Forma

- 7 Asimetría (skewness): forma de los datos; qué tan simétrica es la distribución respecto a su media.
- 8 Curtosis: concentración de datos extremos (presencia de colas más pronunciadas o aplanadas).

Medidas basadas en momentos

orden	medida	fórmula	qué información captura
1	media	$\mu = \frac{1}{n} \sum_{i=1}^n x_i$	Centro Es el punto de equilibrio de los datos.
2	varianza	$\sigma^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2$	Dispersión Mide qué tan lejos están los datos de la media.
3	asimetría	$\frac{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^3}{\sigma^3}$	Sesgo Mide si la distribución está sesgada hacia la izquierda o derecha.
4	curtosis	$\frac{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^4}{\sigma^4}$	Extremos y forma Mide la "pesadez" de las colas de la distribución y qué tan puntiaguda es.

EDA variables categóricas



Concentración de categorías

- 1 Moda: valor más frecuente.
- 2 Proporción de la moda: qué proporción del total está representado por la moda.
- 3 Multimodalidad. Permite detectar si la distribución está dominada por una sola categoría.

Distribución y frecuencia

- 4 Frecuencia absoluta: número de veces que aparece cada categoría. [Grafico de barras](#)
- 5 Frecuencia relativa: Proporción de cada categoría respecto al total de observaciones. [Grafico de torta](#)
- 6 Rango de frecuencias: diferencia entre la categoría más frecuente y la menos frecuente.

Diversidad o variabilidad

- 7 Cardinalidad: número de categorías únicas.
- 8 Entropía de Shannon: medida de incertidumbre o diversidad de la distribución.

Ejemplos en Python


Revisar la Notebook
clase_02_intro_EDA.ipynb (se encuentra
en la carpeta "notebooks" del repositorio).



Por ahora el objetivo es ENTENDER los datos, no tratarlos

Outliers

- Los outliers son puntos que difieren significativamente de otras observaciones en un dataset.
- Identificar outliers es crucial porque:
 - indican errores o anomalías en los datos.
 - permiten resaltar hallazgos inusuales pero significativos.
 - pueden afectar a los modelos estadísticos o predictivos, y llevar a interpretaciones o predicciones incorrectas.
- Si no se manejan adecuadamente, los outliers pueden sesgar el análisis y conducir a conclusiones erradas.




Si el outlier es una anomalía, puede ser un dato significativo. Si es un error no dice nada
Para que un modelo funcione bien, se deben tratar los outliers

Técnicas para detectar outliers


Análisis visual

outliers


- Boxplots



- Histogramas




- Scatterplots



Técnicas para detectar outliers

Métodos estadísticos

- datos menores a $(Q1 - 1.5 \cdot IQR)$ o mayores a $(Q3 + 1.5 \cdot IQR)$




Técnicas para detectar outliers

Métodos estadísticos

- datos menores a (media - 3 STD) o mayores a (media + 3 STD)

Sí los datos tienen una distribución mas o menos normal

Todo lo que este por fuera de ± 3 STD es outlier



(asumo distribución normal!)

Datos faltantes ¿qué son?

	F	G	H	I	J
A	0.620576	0.140053	1.352728	NaN	0.808078
B	NaN	0.526829	NaN	NaN	0.170902
C	NaN	0.458827	1.406713	0.071119	NaN
D	NaN	2.307197	NaN	NaN	NaN
E	0.203402	0.259913	NaN	0.505811	1.516755

Missing data

- Son observaciones incompletas o valores no registrados en el dataset (NaN, null).
- Pueden distorsionar el análisis y los modelos si no se tratan (introducir bias y afectar la confiabilidad).

Tipos de causas de datos faltantes

Es importante saber la causa de datos faltantes para saber que tecnicas aplicar

- **MCAR (Missing Completely at Random):** el valor falta por una causa al azar y su falta es independiente de los datos. Es un mecanismo que no introduce sesgo.
- **MAR (Missing at Random):** la falta del valor se relaciona con los datos de otras columnas. Existe un patron
- **MNAR (Missing Not at Random):** la falta depende del dato no observado y se debe a una causa especifica que debe ser investigada.



Ejemplo 1

Ejemplo: estamos investigando salarios en Argentina y enviamos una encuesta a 100 personas.

Participante	Edad	Rubro	Salario
1	29	Abogado/a	1.500.000
2	53	Profesor	430.000
3	21	Null	1.350.000
4	34	Analista de marketing	1.000.000
5	Null	A. financiero/a	600.000
5	31	Asesor/a del congreso	700.000
6	48	Recepcionista	770.000
.....			

Los encuestados se olvidaron de responder algunos campos de la encuesta.

MCAR?

Como los datos faltantes son aleatorios, sí es MCAR

Ejemplo 2

Ejemplo: estamos investigando salarios en Argentina y enviamos una encuesta a 100 personas.

Participante	Edad	Rubro	Salario
1	29	Abogado/a	1.500.000
2	37	Profesor/a	430.000
3	53	Analista de datos	Null
4	34	Analista de marketing	1.000.000
5	23	A. financiero/a	600.000
5	31	Asesor/a del congreso	700.000
6	48	Recepcionista	Null
.....			

Los entrevistados mayores de 40 son menos propensos a divulgar su salario.

Hay un patrón, la falta depende de los datos observados (la edad).

MAR?

Ejemplo 3

Ejemplo: estamos investigando salarios en Argentina y enviamos una encuesta a 100 personas.

Participante	Edad	Rubro	Salario
1	45	Abogado/a	Null
2	52	Profesor/a	430.000
3	21	Analista de datos	Null
4	34	Analista de marketing	Null
5	23	A. financiero/a	600.000
5	31	Asesor/a del congreso	700.000
6	48	Recepcionista	770.000
.....			

Las personas con salarios más altos tienden a evitar contestar la pregunta.

La falta depende del dato que no tengo

MNAR?

Uno más....

Participante	Edad	Año de graduación	Rubro	Salario
1	45	2006	Abogado/a	1.500.000
2	52	1998	Profesor/a	430.000
3	21	Null	Analista de datos	1.350.000
4	34	Null	Analista de marketing	1.000.000
5	23	2024	A. financiero/a	600.000
5	31	2020	Asesor/a del congreso	700.000
6	48	Null	Recepcionista	770.000
.....				

Los faltantes corresponden a personas que no se han graduado

¿Qué podemos decir en este caso?

En este caso "Año de graduación" tiene nulos pero tiene sentido que no este.
No es un dato faltante, la persona no se graduo.

Falta estructural o por diseño

- Los mecanismos de datos faltantes anteriores implican que el dato debería estar pero por algún motivo no aparece.
- En el caso de la falta por diseño, no es un problema de la recolección de datos. ¡Tiene sentido que el dato no esté!



Siempre antes de entrenar un modelo, hay que tratar los datos faltantes!!!

Algunas formas de analizar causas de faltantes

- Métodos gráficos (bibliotecas especiales) para analizar si hay o no patrones.
- EDA - Relaciones entre variables.
- Filtrado / agrupamiento (por ej, es MCAR si el porcentaje de faltantes es aprox. el mismo al agrupar de distintas maneras.
- Tests estadísticos. En general, se usa tests de hipotesis



En definitiva...



- No podemos saber a ciencia cierta qué mecanismo gobierna la falta de datos.
- Con un buen análisis y entendimiento del dominio se pueden hacer hipótesis razonables.

Ejemplos prácticos en Jupyter



Actividad

- Identificar características generales (por ej. tamaño, tipo de información, curiosidades, desafíos a priori, etc.) del dataset seleccionado para los trabajos prácticos.
- Resumir esta información en 1-2 diapositivas.



En la clase 3, cada grupo tendrá 3 minutos para exponer sus diapositivas.
Previo a la clase, las docentes compartirán una presentación de Google Slides para que peguen allí las diapositivas que usarán.

¿Te quedaron dudas?



- Recordá que podés consultarnos durante la clase preniendo la cámara y hablando, o simplemente escribiendo en el chat.
- También podés escribirnos por correo las veces que sea necesario.



Esp. Lic. María Carina Roldán
macroldan@fi.uba.ar



Esp. Ing. Ariadna Garmendia
arigarmendia@gmail.com

Y si tenés un feedback, un pedido, una sugerencia, etc. y no te animás a decirlo, podés dejarlo por escrito en la encuesta voluntaria y anónima (disponible durante todo el bimestre).