

Análisis de datos

Carrera de Especialización en
Inteligencia Artificial
B4 2025



Programa de la materia

1 **Introducción al análisis de datos**
Flujo de trabajo típico. Aplicaciones. Configuración del entorno. Introducción a las principales bibliotecas.
28/8

2 **Análisis exploratorio de datos (EDA)**
Tipos de variables. EDA y visualización de variables numéricas y categóricas. Identificación de valores faltantes y outliers. Relación entre variables.
4/9

3 **Taller práctico - parte 1**
Trabajo en grupos: EDA y visualización inicial de un dataset. Buenas prácticas. Puesta en común.
11/9

4 **Preprocesamiento y limpieza de datos**
Flujo de preparación de datos. Prevención de data leakage. Tratamiento de datos faltantes y outliers. Cardinalidad. Codificación. Discretización.
18/9

5 **Procesamiento (continuación)**
Normalización y estandarización. Técnicas avanzadas para el tratamiento de datos faltantes y outliers. Desbalance. Creación de nuevos features.
25/9

6 **Reducción de dimensionalidad**
Métodos de extracción y técnicas para selección de features. **Bonus:** EDA y procesamiento básico de datos no estructurados.
2/10

7 **Taller práctico - parte 2**
Trabajo en grupo: preprocesamiento y feature engineering de un dataset. Buenas prácticas. Puesta en común. Consultas.
9/10



13/10 - límite para compartir el material para la exposición final.

8 **Exposición final**
Exposición de trabajos finales.
Bonus: Herramientas para automatizar el EDA y otras tareas del flujo de trabajo.
16/10



Dimensionalidad



Se llama **dimensionalidad** al número de variables (features) en un dataset.

a	b	c	d	e	f	g

Problemas con la alta dimensionalidad

Los datos con alta dimensionalidad son difíciles de analizar y visualizar. Además, pueden llegar a ocupar mucho espacio.

La maldición de la dimensionalidad

A medida que las dimensiones aumentan:

- los puntos de datos se vuelven escasos.
- las distancias entre puntos pierden significado.
- el costo computacional aumenta exponencialmente.
- se corre el riesgo de tener *overfitting*.

Si la proporción entre cantidad de columnas y observaciones no es grande, puede generar overfitting


Solución

Crear un espacio de features de menor dimensión al original.



Técnicas de reducción de dimensionalidad

Selección de features




Elegir un subconjunto de features.

Elijo con cuales me quedo: si son relevantes, si una es multiplo de otra, etc

Ejemplo de aplicación:

- Existencia de features altamente correlacionadas.

Extracción de features



Transformar los datos en un espacio de menos dimensiones.

Aca no se seleccionan features, sino que se transforman a otro espacio de dimensiones.

Ejemplo de aplicación:

- Análisis de datos genómicos.

→ Técnicas de selección de features

MÉTODOS DE FILTRADO

- Umbral de varianza
- Correlación con la v. target
- Pairwise correlation
- ANOVA
- Chi-cuadrado
- Información mutua

MÉTODOS INTRÍNSECOS

Embebidos en el entrenamiento:

- Basados en árboles
- Basados en regularización:
 - Regresión Lasso
 - SVM + L1

MÉTODOS WRAPPER


Objetivo: optimizar la performance predictiva.

- RFE (Recursive Feature Elimination)
- SFS (Sequential Feature Selection)
- Permutation importance



Nuestro foco

Métodos de filtrado



- Son formas muy simples de remover features antes del entrenamiento de modelos.
- Evalúan las propiedades intrínsecas de las variables (por lo general mediante alguna medida estadística).

Repaso de tests estadísticos

Se cuenta con una muestra de los datos y se trata de medir lo que sucede en esa muestra. Luego con métodos estadísticos, se observa si lo que se tiene en la muestra es representativo de un dataset más grande.

- Tests de hipótesis: son una manera de evaluar la evidencia de alguna afirmación sobre parámetros de una población a partir de datos de una muestra.
- Usa 2 hipótesis, **H0, la hipótesis nula**, y **H1, la hipótesis alternativa** (generalmente la que interesa). Por medio de un **estadístico de prueba** (t-test, chi-cuadrado, etc.), el test evalúa qué tan distinto de H0 es lo que veo en mi muestra.
- El **p-valor** indica qué tan probable es obtener resultados tan o más extremos que los observados en mi muestra si H0 es cierta. Si el p-valor es suficientemente pequeño, puedo rechazar H0.
- Para evaluar el p-valor, lo comparo contra un umbral predefinido, el **nivel de significancia α** (comúnmente 0,05). Si p-valor $\leq \alpha$, considero que mis resultados no son por azar y que hay evidencia significativa para rechazar H0.
- Atención!
 - **No rechazar H0 $\leftrightarrow$ aceptar H0**. No rechazar significa que no tengo evidencia suficiente para hacerlo (se podría deber a una muestra insuficiente)
 - **Rechazar H0 $\leftrightarrow$ aceptar H1**. Rechazar solo significa que la evidencia es más consistente H1, aunque otros modelos/otras hipótesis podrían explicar mejor los resultados.

Que se cumpla algo es solo un indicador, no una verdad absoluta!

Por ejemplo, para ver relaciones entre variables.

Pasos para el cálculo (prueba unilateral derecha)

- 1) Armamos las hipótesis.
- 2) Con las observaciones, calculamos el estadístico correspondiente.
- 3) Calculamos el p-valor con la CDF:
$$\text{p-valor} = 1 - \text{CDF}(\text{estadístico observado})$$



Cómo hacer los tests con scikit-learn

H1: los features individuales del dataset, cuando se consideran aisladamente, tienen una relación que es estadísticamente significativa con la variable target.

SelectkBest: selecciona los K con p-valores más pequeños (yo le indico el número K)

SelectFpr: selecciona los que tienen un p-valor $\leq \alpha$ ($\alpha=0,05$ por defecto)



Correlación de Pearson

Para variables numerica-numerica

Coeficiente de correlación de Pearson para n muestras:

$$r_{XY} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

Resultado:

- $r=1$ ó $r=-1$: indica que x e y están perfectamente relacionadas (-1 indica que cuando una crece, la otra decrece).
- $0 < r < 1$: hay una relación lineal, pero no perfecta

Supuestos de la correlación:

- Mide la **fuerza** y la **dirección** de la asociación lineal entre dos variables.
- Asume que la distribución de los datos es Normal.
- No distingue cuál es la variable dependiente y cuál la independiente. ($r_{XY} = r_{YX}$)
- **Muy importante!** la correlación no indica ninguna medida de la importancia significativa de la relación (es decir, si esto vale también para la población de los datos y no solo en la muestra).

La correlacion de Pearson es sensible a outliers.

El resultado de la correlacion es un valor, pero no es el p-valor. Por lo tanto, no se sabe si el valor es estadisticamente significativa.

Correlaciones por rankings de Spearman y Kendall

Para variables
numérica-numérica

Para relaciones que no son lineales o datos que no siguen una distribución normal.

Coeficiente de correlación de Spearman para n muestras:

$$r_s = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

- d_i son las diferencias entre rankings

Coeficiente de correlación de Kendall para n muestras:

$$\tau = \frac{C - D}{\frac{n(n-1)}{2}} = \frac{C - D}{C + D}$$

Kendall es mejor cuando hay datos que se repiten mucho

- C = número de pares concordantes
- D = número de pares discordantes

- Miden la fuerza y la dirección de una relación monótona entre dos variables.
- No asumen distribución Normal de los datos.
- Son robustos a outliers.
- Ambos utilizan rankings para hacer los cálculos.
- Los resultados están en $[-1, 1]$ al igual que con Pearson.
- Usar Kendall cuando hay empates (cuando las variables tienen valores repetidos). porque Spearman pierde.

Ejemplo

Selección con Chi-cuadrado

Para variables
categóricas-categoricas

- Sirve para averiguar si hay una relación entre dos variables categóricas.
- Para el análisis compara las frecuencias observadas y las frecuencias esperadas (qué se esperaría ver si las variables fueran independientes)
- Un mayor valor del estadístico representa una relación más fuerte.

$$\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i}$$

- O_i son las frecuencias observadas
- E_i son las frecuencias esperadas

Atención!

- Supuesto: las frecuencias esperadas son >5
- No está pensado para variables ordinales (en ese caso conviene usar análisis basado en rankings).

Spearman o Kendall



ANOVA (Análisis de varianza) de 1 vía

Para variables numerica-categorica


- Ayuda a analizar si una variable numérica proporciona información importante para distinguir entre categorías (target).

Se basa en analizar las medias de los distintos grupos.

El objetivo es distinguir si las medias de las variables numericas estan suficientemente separadas, entonces se puede distinguir las clases del target a traves de esta variable

- Plantea lo siguiente:
 - H0: las medias de todos los grupos son iguales
 - H1: al menos una de las medias es diferente de las otras

- Utiliza un estadístico "F" que es el ratio entre dos varianzas:
- Los grupos tienen distintas medias cuando la varianza entre grupos es mucho mayor que la varianza en los grupos.
- A mayor F, mayor es el poder predictivo que tiene la variable.
- Supuestos:
 - La variable independiente es categórica (nominal). La dependiente es numérica.
 - Distribución Normal de los datos.
 - El test supone que las varianzas de cada grupo son iguales.



$$F = \frac{\text{varianza}_{\text{entre-grupos}}}{\text{varianza}_{\text{grupos}}}$$

El total

de cada grupo

Por medio de ANOVA se determina un p-valor y se evalúa su significancia.

No asume nada y se puede usar para ver la relación para (casi) cualquier variable

Información mutua

$$I(X, Y) = H(Y) - \underline{H(Y|X)}$$

A medida que más conozca Y a través de X, este valor de entropía es cada vez más chico, y por lo tanto, el resultado es más grande. Entonces cuanto más grande I, más valor predictivo tiene X sobre Y

- Se calcula a partir de la entropía individual $H(y)$ y la conjunta $H(y|x)$.
 Medida de la información
- Indica en qué medida una variable proporciona información sobre otra variable (por ej "y", el target).
- Mide cuánto se reduce la incertidumbre sobre la variable objetivo al conocer esa variable.
- Mientras más grande sea el valor de la información mutua calculada, más poder predictivo tiene ese feature sobre el target.
- A diferencia del método de correlación, el resultado no da idea de "fuerza de la relación", sino que sirve para comparar.
Entonces, se calcula la información mutua de todas las variables con el target, y se eligen los valores más grandes.



¿Cuándo usar cada método de filtrado?

Variable de entrada	Variable de salida	Tipo de filtro	Supuestos/ Consideraciones
Todas	N/A	Umbral de varianza	- No tiene en cuenta a la variable target. - Las variables tienen que estar en la misma escala.
Numérica	Numérica	- Pearson - Spearman - Kendall - Información mutua*	- Pearson: relación lineal entre variables. Asume distribución Normal de los datos. Sensible a outliers. - Spearman y Kendall asumen relación monótona entre variables. Robustos ante outliers por usar rangos. Kendall es mejor si hay valores repetidos en cualquiera de las variables a comparar.
Numérica	Categórica	- ANOVA - Kendall - Información mutua*	- ANOVA supone normalidad de los datos en cada grupo. Alternativa: Kruskal-Wallis (no paramétrico). También supone varianzas homogéneas (homocedasticidad). Alternativa: Welch-ANOVA. - Kendall asume relación monótona entre variables. La variable categórica de entrada o salida debe ser ordinal.
Categórica	Numérica		
Categórica	Categórica	- Chi-cuadrado - Información mutua*	- Chi-cuadrado: valores positivos y discretos. Buena para features categóricos (nominales). * Información mutua: no asume distribución y puede capturar relaciones no lineales.

Ejemplo práctico



→ Extracción de features

Objetivo

Reducir la dimensionalidad conservando la mayor cantidad de información posible.

Técnicas

- PCA (*Principal Component Analysis*)
- LDA (*Linear Discriminant Analysis*)
- t-SNE (*t-distributed Stochastic Neighbor Embedding*)
- UMAP (*Uniform Manifold Association and Projection*)

Análisis de los componentes principales (PCA)

- Es un método lineal.
- Crea componentes ortogonales (no correlacionados).
- Los nuevos ejes maximizan la varianza.




PCA proyecta "coordenadas" de un sistema a otro

Generalmente se aplica PCA cuando se tienen muchas dimensiones.



Análisis de los componentes principales (PCA)

¿Por qué es importante la varianza?



- Recordemos: la varianza mide la dispersión de los datos alrededor de la media.
- En un dataset con muchos *features*, cada feature contribuye a la variación de los datos en mayor o menor medida.
- Retener la máxima varianza implica mantener las componentes que explican la porción más grande de esa variación.

Análisis de los componentes principales (PCA). Ejemplo.



Explicación de la varianza

PC1 74,52 %

PC2 17,25 %


PC3 8,23 %

proporcion de los autovalores




Análisis de los componentes principales (PCA)

En general:



Análisis de los componentes principales (PCA)

En general:



Ejemplo práctico en Jupyter



Análisis Discriminante Lineal (LDA)

- Es un método lineal.
- Es una técnica **supervisada**.
- Maximiza la separabilidad de las clases.
- Es útil para clasificación.


Comparación con PCA

- PCA captura la varianza y no conoce etiquetas.
- LDA se enfoca en la separación de clases.



¿Cómo funciona LDA?

- Busca maximizar distancia entre medias + minimizar la varianza (scatter) de cada categoría.



Crea uno o más ejes nuevos y sobre estos proyecta los datos, de forma que se maximice la separación entre las categorías (clases).

En gral, el algoritmo devuelve:

- LD1, el eje que muestra la mayor variación entre categorías.
- LD2, el segundo mejor.
- Etc.

¿Qué significa que una técnica preserve información global o local?

Mantener estructura global: conservar la relación general entre los puntos en el conjunto de datos, como por ejemplo la varianza.

Mantener estructura local: preservar las relaciones entre puntos cercanos.

Ej: estamos monitoreando datos de sensores de una máquina y queremos captar anomalías sutiles.

t-Distributed Stochastic Neighbor Embedding (t-SNE)

- Es un método no lineal.
- Bueno para visualización.
- Preserva la estructura local. No preserva bien la global.
- Computacionalmente caro.
- Es bueno para datasets pequeños.


⚠ No es para reducción de *features*, solo para visualización.

Funcionamiento de t-SNE

- Busca proyectar los datos en un espacio de dimensiones reducidas de manera tal que se mantengan los clusters de puntos del espacio de alta dimensión.

Pasos simplificados (Ej., 2D a 1D):

- 1) Determina la "similitud" entre cada punto y todos los demás.
- 2) Guarda todas las similitudes en una matriz.
- 3) Proyecta todos los puntos en forma aleatoria en un eje (1D).
- 4) Calcula matriz de similitudes.
- 5) Mueve los puntos poco a poco para que la matriz de 1D se parezca a la de 2D.
- 6) Se detiene cuando alcanza un número dado de iteraciones o cuando ya no hay cambios significativos (el algoritmo converge).



Uniform Manifold Approximation and Projection (UMAP)

- Es un método no lineal.
- Bueno para clustering.
- Preserva estructuras locales y globales.

Comparado con t-SNE:


- Es más rápido.
- Escala bien para grandes datasets.
- Retiene más información global.

UMAP paso a paso

Crea una proyección en un espacio de dimensiones reducidas que preserva clusters presentes en los datos originales y la relación entre ellos.

Funcionamiento (Ej: 2D a 1D)

- 1) Calcula distancias entre todos los puntos.
- 2) Arma un mapa de vecinos y similitudes.
- 3) Inicializa el espacio de dimensión reducida (1D).
- 4) Calcula similitudes en el espacio reducido.
- 5) Ajusta una función para minimizar la diferencia de similitudes entre los espacios 2D y 1D.



Ejemplo práctico



¿Cuándo usar cada técnica de extracción?




Técnica	Cuándo usarla	Consideraciones	Escenarios de uso comunes
PCA	Cuando se necesita un método simple y lineal que retenga la máxima varianza.	• Asume relaciones lineales.	• Preprocesamiento antes de ML. • Reducir ruido. • Comprimir datos.
LDA	Tenemos los datos etiquetados y queremos reducir dimensiones para facilitar la separación entre clases.	• Es para métodos supervisados. • Reduce los datos un máx de $C-1$ (C = núm clases).	• Tareas de clasificación. • Extracción de features para datos etiquetados.
t-SNE	Queremos visualizar datos en muchas dimensiones.	• Costoso computacionalmente. • No supervisado.	• EDA • Visualizar embeddings, vectores de palabras, datos de genómica.
UMAP	Se necesita reducir dim. o visualizar pero también preservar la estructura global y local.	• Bueno para relaciones no lineales y datos complejos. • Más rápido que t-SNE.	• Visualización (alternativa a t-SNE). • Preprocesamiento antes de ML para datos complejos.

Siempre hay un “pero”...





- Al reducir dimensiones se pierde información.
- Técnicas como PCA transforman los features originales y después cuesta interpretarlos.
- La efectividad de la técnica depende del dataset y del problema en cuestión.

Técnicas de selección vs técnicas de reducción




Aspecto	Selección	Extracción
En qué consiste	Conservar un subconjunto de las variables originales (las más relevantes).	Crear nuevas variables (componentes) combinando las originales.
En qué tipo de datasets aplicarla	Dimensionalidad moderada	<u>Dimensionalidad alta</u>
Interpretabilidad	Alta	Baja
Técnicas	Umbral de varianza - Correlación con la v. target - Correlación pairwise - ANOVA - Chi-cuadrado - Información mutua - otras	PCA - LDA - t-SNE - UMAP - otras.

Técnicas de selección vs técnicas de reducción



Ejemplo	Selección	Extracción
Predicción de riesgo de enfermedad con 100 indicadores medidos en sangre.	Usando ANOVA seleccionar solo los indicadores que muestran diferencias significativas entre enfermos y sanos, para preservar la interpretabilidad.	Si el objetivo es predecir rápidamente sin importar los indicadores, usar PCA para obtener factores latentes.
Predicción de abandono a partir de datos de 500 atributos de clientes (edad, ingresos, compras, etc.).	Filtrar con información mutua para conservar las 50 variables con más poder predictivo. Luego entrenar un modelo interpretable (ej. árboles).	Usar PCA para comprimir los 500 atributos en 10 componentes principales. Luego segmentar clientes con K-means.
Análisis de una red de sensores de una planta industrial (2000 lecturas de temperatura, humedad, etc.).	Usar umbral de varianza para eliminar sensores con ruido o mal calibrados.	Usar PCA para fusionar sensores correlacionados. Ej.: PCA puede obtener componentes latentes que mejor representen el calor o la humedad.

Flujo de preparación de datos para IA



BONUS!



→ EDA y preprocesamiento para diferentes tipos de datos

DATOS TABULARES

- variables numéricas y categóricas.
- medias, desvíos, histogramas, etc.

DATOS NO ESTRUCTURADOS

- palabras, píxeles, frecuencias.
- usa visualizaciones y métricas adaptadas a la naturaleza específicas de cada tipo de dato.

En todos los casos se buscan patrones, anomalías, tendencias, desbalanceos, problemas de calidad.




EDA y preprocesamiento para Texto

Qué analizamos en un texto

- Corpus: cantidad de documentos y de palabras.
- Longitud de textos (documentos, oraciones).
- Frecuencia de palabras / tokens.
- Distribución de clases (si es clasificación).
- N-gramas frecuentes.
- TF, DF, TF-IDF (términos relevantes)

Limpieza y preparación de texto

- Eliminar stopwords, signos de puntuación, errores ortográficos.
- Normalizar abreviaturas o expresiones.
- Embeddings + PCA / t-SNE




ne end of the
h how you're livin
ether you're com
nd your free time
ers. It's how you
nd you. It's wh

EDA y preprocesamiento para Audio y Señales

Qué analizamos en un audio

- Duración, amplitud, volumen, formas de onda.
- Espectrogramas
- Análisis de pitch (para analizar entonación, melodía, etc., para distinguir voces, instrumentos, emociones).
- Distribución de clases (si es clasificación)



Limpieza y preparación de audio

- Eliminar archivos corruptos.
- Identificar y remover ruidos, silencios, interferencias.
- Recortar fragmentos irrelevantes.
- Normalizar el volumen.

EDA y preprocesamiento para Imágenes

Limpieza de imágenes

- Eliminar imágenes corruptas.
- Normalizar tamaños o resoluciones.
- Reducir ruido (filtros de mediana, gaussiano).



Análisis y visualización

- Visualizamos imágenes aleatorias.
- Distribución de los valores de los píxeles (histogramas)
- Colores, texturas, formas, iluminación, enfoque, orientación, ruido etc.
- Evaluación de la distribución de clases (desbalance?)



EDA y preprocesamiento para Imágenes

Preparación de imágenes para entrenamiento

- Etiquetado.
- Balancear clases (oversampling / undersampling).
- Data augmentation (rotar, voltear, recortar).
- Selección / extracción de features.



Ejemplo

Imágenes de radiografías con intensidades, texturas, bordes, medidas, etc.

- Selección: quedarse solo con los píxeles con intensidades superiores a un umbral.
- Extracción: transformar las *features* en nuevas representaciones que resuman las texturas y bordes en factores latentes.



Ejemplos prácticos



¿Te quedaron dudas?



- Recordá que podés consultarnos durante la clase preniendo la cámara y hablando, o simplemente escribiendo en el chat.
- También podés escribirnos por correo las veces que sea necesario.



Esp. Lic. María Carina Roldán
macroldan@fi.uba.ar



Esp. Ing. Ariadna Garmendia
arigarmendia@gmail.com

Y si tenés un feedback, un pedido, una sugerencia, etc. y no te animás a decirlo, podés dejarlo por escrito en la encuesta voluntaria y anónima (disponible durante todo el bimestre).